


Adecuado cuando tenemos pocos datos, muchas características y en conjunto con redes neuronales.

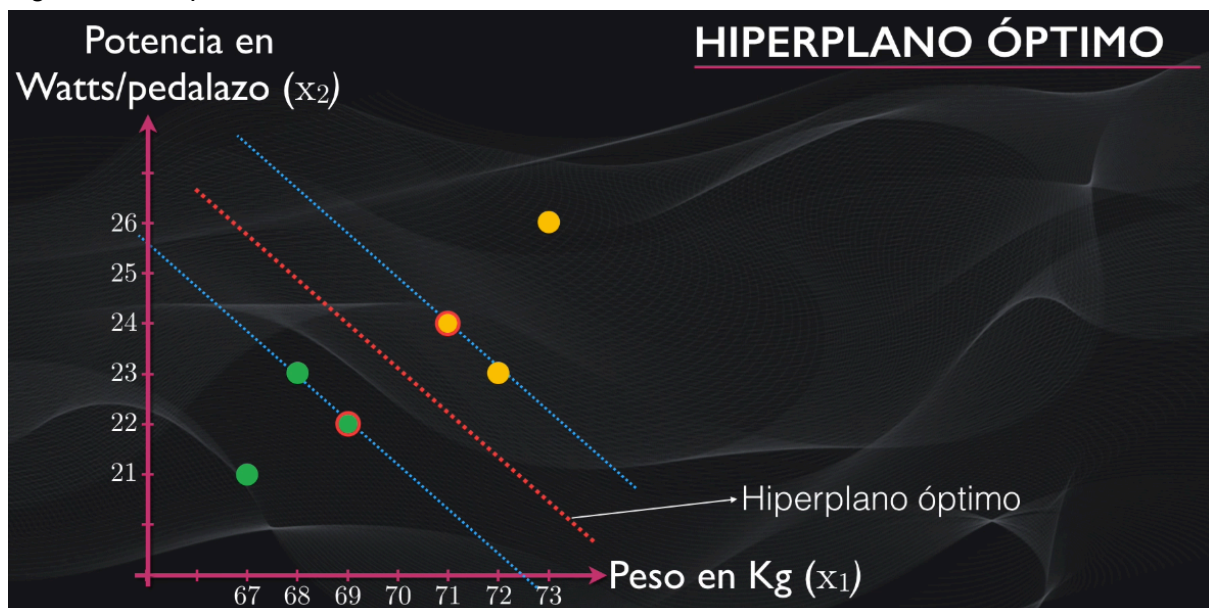
Vectores de soporte:

Los vectores de soporte, que son precisamente los puntos más cercanos entre una clase y otra, y son los que le dan el nombre al algoritmo



Hiperplano:

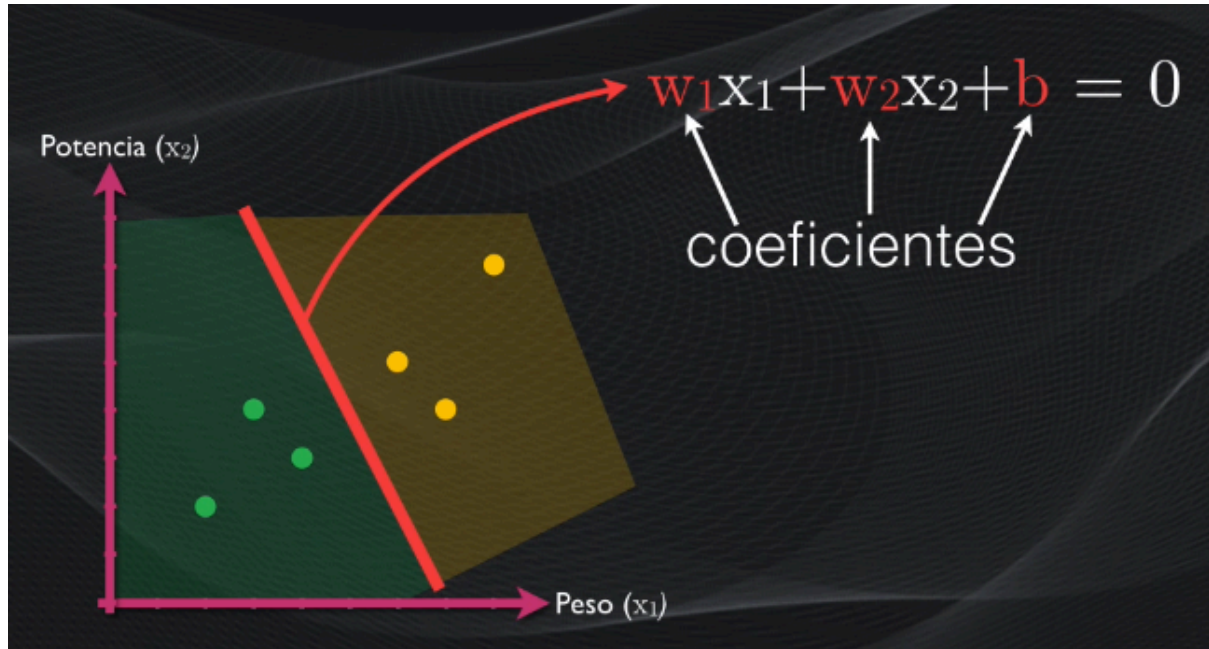
Es una generalización de un plano en dimensiones superiores, que se utiliza para separar clases en el espacio de características. Es el límite de decisión que divide el espacio en dos regiones, una para cada clase



Hard Margin

Se refiere a la situación en la que se busca un hiperplano que separe perfectamente las clases en el espacio de características, sin permitir ningún error de clasificación.

Soft Margin, originalmente en el clasificador hard margin se buscaba maximizar el margen, y para esto se modificaban únicamente los coeficientes del hiperplano



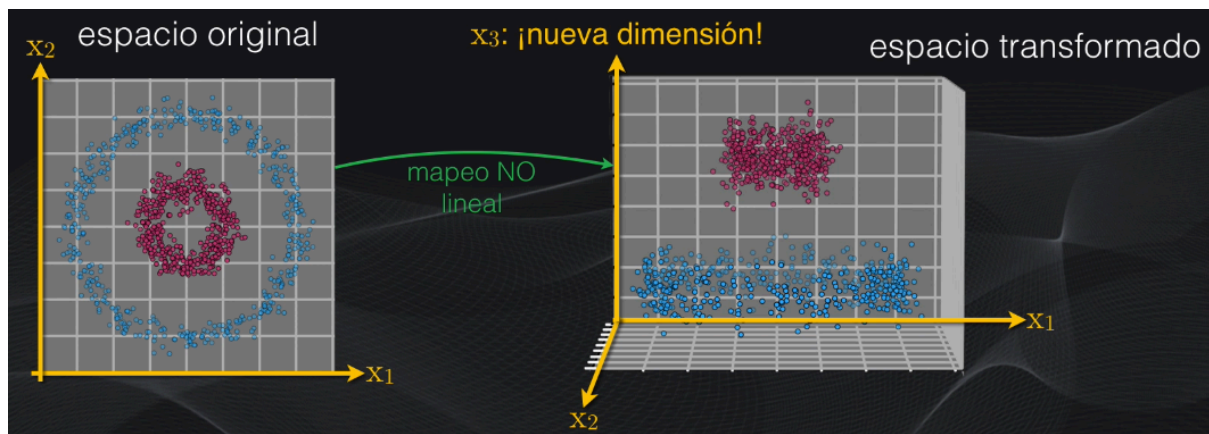
Kernel

Son funciones que transforman el espacio de características original a un espacio de características de mayor dimensionalidad, permitiendo así la separación de clases que no son linealmente separables en el espacio original

Básicamente consiste en tomar el set de datos original, que no es separable, y mapearlo a un espacio de mayores dimensiones usando una función no lineal.

-Las polinomiales, que implican obtener combinaciones de los vectores de características usando potencias mayores que 1

-Usando funciones gaussianas, con forma de campana, que se conocen como funciones de base radial.



Problemas (Utilidades) de SVM:

Diagnóstico médico: Puede ser utilizado para clasificar imágenes médicas para el diagnóstico de enfermedades como el cáncer, utilizando características extraídas de las imágenes.

Clasificación de Texto: Puede ser útil para clasificar documentos en categorías como spam, o para la clasificación de noticias en diferentes temas.

Reconocimiento de voz: Puede ser útil para clasificar señales de voz en diferentes palabras o frases, utilizando características extraídas de la señal de audio.

Problemas (No Utilidades) de SVM:

Grandes conjuntos de datos: Puede volverse computacionalmente costoso en conjuntos de datos muy grandes, debido a su complejidad computacional.

Predicción de series temporales: Puede no ser la mejor opción para predecir series temporales, ya que no tiene en cuenta la dependencia temporal entre las observaciones.

Datos ruidosos: Si los datos contienen mucho ruido o solapamiento entre clases, SVM puede no ser la mejor opción ya que tiende a ser sensible a esos casos